


Classificação de dígitos com redes neurais

Luiza Pozzobon

Algoritmos de Otimização

Problema - Dataset MNIST

- Classificação de imagens em P&B de 28 por 28 pixels em 10 classes: de 0 a 9.
- Dados disponíveis
 - **60000** imagens de **treino**
 - **10000** imagens de **teste**




(a) MNIST sample belonging to the digit '7'.



Modelo de Rede Neural

- 3 camadas lineares com função de ativação **ReLU** na saída.



- 1ª Camada - Entrada:

- Entrada: 784 neurônios
- Saída: 256 neurônios

- 2ª Camada - *Hidden layer*:


- Entrada: 256 neurônios
- Saída: 256 neurônios

- 3ª Camada - Saída:

- Entrada: 256 neurônios
- Saída: 10 neurônios


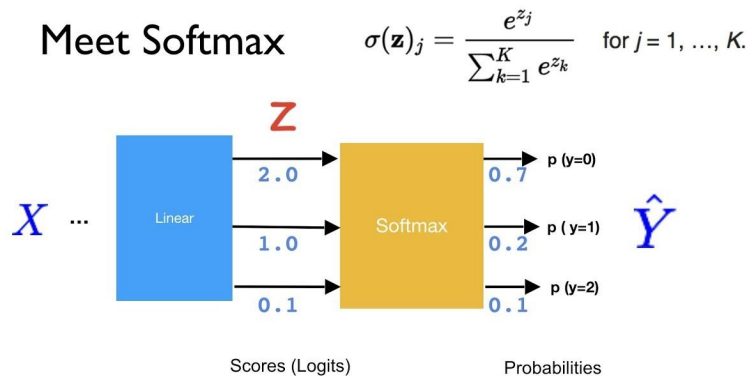
- Os rótulos de cada imagem, numerados de **0 a 9**, são transformados para o modo '**One-hot-encoding**':

0: [1 0 0 0 0 0 0 0 0 0]; 1: [0 1 0 0 0 0 0 0 0 0]; 2: [0 0 1 0 0 0 0 0 0 0]; ...



Função de Custo


- Saída da rede tem o mesmo formato, por isso tem 10 neurônios.
- Saída da rede é passada pela função de **Softmax**, para que o vetor some, ao todo **1**. A **posição do maior valor** do novo vetor corresponde à **classe**.
- Saída da **Softmax** passa pela **probabilidade negativa do log** para cálculo do erro.
- Ao fim, tem-se o custo chamado **cross-entropy**.



Inicialização

- Pesos iniciados aleatoriamente entre 0 e 0,001.
- Bias de cada neurônio iniciados em 1.

Pesos iniciais pequenos e randomizados colaboram com a convergência da rede




Hiperparâmetros

- Treino por 25 épocas
- Batch size de 128
- Learning rate de 0,03
- Redução da learning rate em 10% nas épocas 10 e 20.

1 Época = todas as N imagens disponíveis passam pela rede uma vez



128 imagens passadas pela rede a cada iteração ou "batch"

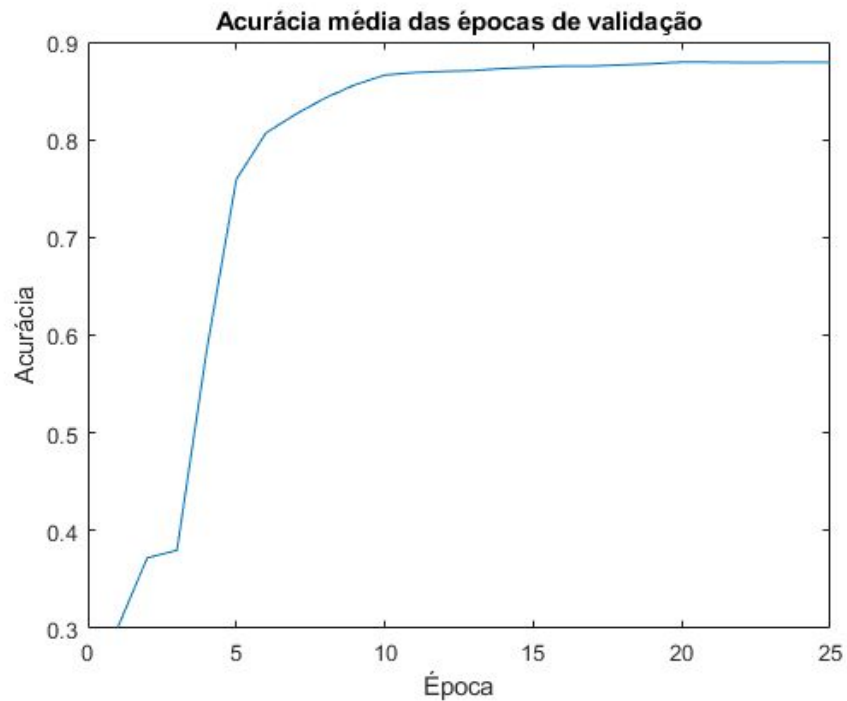


Número de batches = Imagens disponíveis / batch size




Resultados


Acurácia: 87,93%



Erro: 0,1756




Resultados de Validação - Dataset MNIST



Resultados de Teste - Imagens próprias

Pré-processamento das imagens





Classificação das imagens



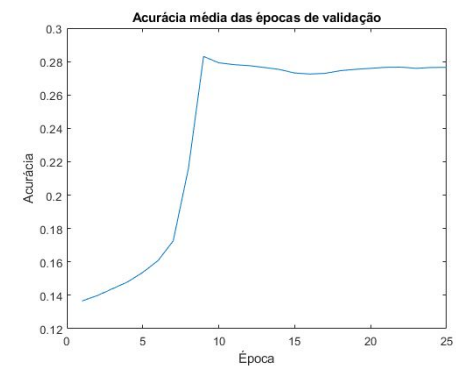

Como a quantia de dados de treino influencia a acurácia?

Dados de Treino	Acurácia	Erro
60000	87,93%	0,1756
30000	77,47%	0,3903
15000	39,44%	1,1182
5000	27,65%	1,5865

60000 imagens



5000 imagens



Obrigada!

Referências

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep learning. Book in preparation for MIT Press. **URL;** [http://www. deeplearningbook. org](http://www.deeplearningbook.org), 2016.

TRASK, Andrew. **Grokking deep learning**. Manning Publications Co., 2019.

<https://towardsdatascience.com/neural-net-from-scratch-using-numpy-71a31f6e3675>

<https://towardsdatascience.com/building-an-artificial-neural-network-using-pure-numpy-3fe21acc5815>

<https://zhenye-na.github.io/2018/09/09/build-neural-network-with-mnist-from-scratch.html>

<https://medium.com/data-science-bootcamp/understand-cross-entropy-loss-in-minutes-9fb263caee9a>